


Retrieval (huggingface)

사용한 데이터는 크게 두가지로 구성된다. 구데이터 (125개파일), 신데이터 (125개파일)이다.

각각은 parsing과 내부structure가 다르게 형성되어있다. 이를 바탕으로 각 logic을 다르게 구조화해봄으로써 각각의 접근 방법에 대해 실험해보고자한다. 이에 대한 성능지표로는 RAGAS을 사용하였고, 이에사용한 모델은 모두 공통적으로 gpt 4.1 mini를 통일시켰다. 추가적으로, 다현님이 만들어주신 모델 평가 지표(phase3,4,)를 활용한 결과 또한 포함하고 있다.

내용구성은 각 데이터마다 사용한 접근방식이 다르기에 이를 중심으로 두가지 방법을 큰 축으로 설명하고자 한다. 각 세부내용은 huggingface에서 제공하는 embedding model와 llm을 선별하여 실험진행과정을 담고 있다. 특히, llm은 sh2orc/Llama-3.1-Korean-8B-Instruct 와 Qwen 0.6B 모델을 중심으로 비교해본 결과, 한국에 모델에서 답변생성이 더 만족스러운 결과를 가져왔기에, 이를 중심으로 모든 실험을 진행하고 있다.



1. 구데이터 (125)

1) embedding model: kure_v1과 bge-3m, KoE5

가장 먼저 선별한 embedding model은 kure_v1과 bge-3m, KoE5 였다. 선별이유는 공공기관 문서이기때문에, 한글에 특화된 모델을 중심으로 실험을 진행하고자 했기 때문이다.

특히, Kure_V1은 bge-3m을 한국어에 맞게 pre-training시킨 모델로 둘의 성능비교는 multilingual model과의 차이를 더 극명하게 확인하고자 가져온 케이스이다. 또한, top_k의 수치를 여러번 비교실험해봄으로써, 얼마나 많은 후보군 속에서 정확한 결과가 도출되지는 비교실험해보았다. 그 결과는 아래의 표와 같다.

	모델	top_k	hit_rate	mrr	\tndcg	multi_doc_recall	n
0	KuRe	1	0.9000	0.9000	0.9000	0.7833	30
1	BGE-M3	1	0.8667	0.8667	0.8667	0.7500	30
2	KoE5	1	0.8333	0.8333	0.8333	0.7000	30
3	KuRe	3	0.9667	0.9333	0.9034	0.9167	30
4	BGE-M3	3	0.9667	0.9111	0.8969	0.9333	30
5	KoE5	3	0.9333	0.8778	0.8276	0.8500	30
6	KuRe	5	1.0000	0.9417	0.9122	0.9333	30
7	BGE-M3	5	1.0000	0.9194	0.9057	0.9500	30
8	KoE5	5	0.9667	0.8861	0.8666	0.9333	30
9	KuRe	10	1.0000	0.9417	0.9122	0.9333	30
10	BGE-M3	10	1.0000	0.9194	0.9057	0.9500	30
11	KoE5	10	0.9667	0.8861	0.8738	0.9500	30

[표1] 후보군에 따른 Embedding Model 비교실험결과

구분	KoE5 (n)	\tKuRe (n)	BGE-M3 (n)	난이도	\tKoE5 (n)	KuRe (n)	BGE-M3 (n)
0 type=A	0.9590 (9)	1.0000 (9)	0.9590 (9)	0 상 (어려움)	0.8733 (7)	0.9447 (7)	0.9447 (7)
1 type=B	0.8292 (7)	0.7291 (7)	0.7729 (7)	1 중 (보통)	0.7366 (7)	0.8421 (7)	0.7682 (7)
2 type=C	0.9077 (4)	0.9077 (4)	0.8750 (4)	2 하 (쉬움)	0.9021 (13)	0.9121 (13)	0.9370 (13)
3 type=E	0.7044 (7)	0.9473 (7)	0.9473 (7)				

	model	encode_ms	search_ms	total_ms
0	KoE5	8.896	9.340	18.236
1	KuRe	8.888	8.796	17.684
2	BGE-M3	8.333	171.874	180.207

[표2,3,4] type별, 난이도별, latency별 각 모델 성능지표

또한, 평가데이터셋은 5가지 type과 3단계의 난이도로 구성되어있다. A는 단일 문서 직접 질의, B는 다중 문서 비교, 차액계산, C는 대화 이력 기반 후속 질의, D는 문서에 존재하지 않는 정보 질의, E는 이상한 틀린 글자/오타이며, 상, 계산, 복잡이고, 중은 추론, 비교, 맥락, 하는 문서기반찾기 평가항목으로 구성되었다. 이를 중심으로 각 모델의 성능을 비교해보았을 때, 표 2,3,4에서 볼 수 있듯이, Kure모델이 전반적으로 좋은 성능을 보여주고 있다.

그럼에도, KURE자체는 B type에 취약했던 부분이 존재함을 알 수 있었다. 이부분은 metadata filter부분을 보았을 때, agency가 각 들어있는 retrieval이 진행이 잘 되지만, 다중으로 잡혀있는 경우 그러지 않음을 볼 수 있었다. 그래서 multi-documetation의 경우, 아래 표와 같이 groud_truth_docs를 활용해 다중지표를 세분화하는 방법을 택했다.


Id	type	difficulty	question	ground_truth_answer	ground_truth_docs	metadata_filter	history
Q001	A	하	한국가스공사의 '차세' 해당 사업의 예산 규모	['한국가스공사_']	['한국가스공사_']	['agency': "한국가스"]	
Q002	A	하	고려대학교에서 팔주 해당 사업의 예산은 1	['고려대학교_차세대']	['고려대학교_']	['agency': "고려대학"]	
Q003	A	하	코이카(KOICA) 전자조달 해당 용역의 예산 규모	['KOICA 전자조달_']	['KOICA 전자조달_']	['agency': "KOICA"]	
Q004	A	중	한국가스공사의 ERP 신규 도입 소프트웨어	['한국가스공사_']	['한국가스공사_']	['agency': "한국가스"]	
Q005	A	중	그랜드코리아레저(주) 사업 범위는 그램웨어	['그랜드코리아레저(주)']	['그랜드코리아레저(주)']	['agency': "그랜드코"]	
Q006	A	상	국립중앙의료원의 차/응급실 설/의 자연 문제	['국립중앙의료원_(인)']	['국립중앙의료원_(인)']	['agency': "국립중앙"]	
Q007	B	하	한국가스공사의 '차세' 한국가스공사 사업 예	['한국가스공사_']	['한국가스공사_']	['agency': "다중"]	
Q008	B	하	한국수자원공사의 '용' 한국수자원공사 용역	['한국수자원공사_용']	['한국수자원공사_용']	['agency': "다중"]	
Q009	B	하	그랜드코리아레저(주) 인천광역시 도시계획	['인천광역시_도시계획']	['인천광역시_도시계획']	['agency': "다중"]	
Q010	B	하	국립중앙의료원의 차/국립중앙의료원의 사/국립중앙의료원_(인)	['국립중앙의료원_(인)']	['국립중앙의료원_(인)']	['agency': "다중"]	

[표5] 평가데이터셋 항목

{'agency': ['(사)부산국제영화제', '고양도시관리공사']}
{'agency': ['국립중앙의료원', '한국원자력연구원']}
{'agency': '인천광역시'}
{'agency': ['사단법인아시아물위원회사무국', '서울특별시 여성가족재단']}
{'agency': '한국수자원공사'}
{'agency': ['한국원자력연구원', '서울시립대학교']}
{'agency': ['울산광역시', '케빈랩 주식회사']}

[표6] agency 다중항목 세분화

이는 향후, ui를 구성하는 과정에서 **metdata**항목인, **issuer**를 기본값으로 설정하게 함으로써, 빠르고 정확한 결과를 낼 수 있도록 연계하였다.



2) retrieval 전략

각 데이터의 **logic**구성을 위해 **dense, sparse, hybrid, rerank**등을 가지고 어떤 조합일 때 가장 높은 성능을 보이는지 살펴보고, 이를 기본 구성으로 하여, 그 위에 구성을 쌓는 방법을 택했다. **kurev1**을 가지고 실험하였을때, 아래 표에서 보는 바와 같이, **hybrid 50:50**구성이 가장 좋은 성능을 보였다.

	retriever	n_questions	hit_at_5	mrr_at_5	ndcg_at_5	multi_doc_recall_at_5
0	hybrid_50_dense_50_sparse	28	1.0	0.9821	0.9715	0.9881
1	hybrid_30_dense_70_sparse	28	1.0	0.9821	0.9685	0.9881
2	hybrid_70_dense_30_sparse	28	1.0	0.9821	0.9585	0.9881
3	sparse_bm25	28	1.0	0.9821	0.9121	0.9107
4	rerank_hybrid_cross_encoder	28	1.0	0.9821	0.8843	0.8690
5	contextual_compression_hybrid	28	1.0	0.9464	0.8634	0.8750
6	basic_dense_kure	28	1.0	0.9464	0.8500	0.8631
7	contextual_compression_dense	28	1.0	0.9464	0.8412	0.8452
8	rerank_dense_cross_encoder	28	1.0	1.0000	0.8319	0.7857

[표 7] retrieval 성능비교

3) LLM 과 RAGAS 성능지표비교(정성 및 정량평가)

-LLM 답변

위를 바탕으로 llm결과를 도출해보았을 때, 가장 특징적인 문제는 크게 3가지였다. 하나는 반복, 다른 하나는 언급되지 않은 항목에 대하여, 대답하는 문제, 세번째는, 예산계산의 문제였다. 첫번째문제는 llm의 문제로 **repetive_penalty**를 적용함으로써 해결하고자 했고, 두번째는 이것이 모델의 측면의 문제라면, 모델의 **hallucination**이 문제일테고, 그것이 아니라면, **data**내에서 구조적으로 이부분을 잘 **retrieval**하지 못한 문제일 수도 있다고 판단했다. 세번째는 돈의 구조, 점과 쉼표, 를 돈의 단위로 구분하지 못함과 천원을 000으로 구분하지 못함의 문제였다. 이는 추후 데이터 측면에서 조금더 구조적으로 보완함으로써, **retrieval**부분에서 더 정교화시키는 방향으로 수정되었다.

Q389,B,하,"{"issuer": {"\$in": ["울산광역시", "케빈랩 주식회사"]}},**울산광역시 버스정보망 사업 비용(약 9.86억)이 케빈랩 주식회사 평택시 하천 관제망 사업 비용(약 3.41억)을 수치상 상회하는 폭은 총 얼마입니까?**,

gt> "본 두 개 지자체 생활 밀착형 망 구축 사업비의 현금 단가 수치 격차폭은 645,945,000원에 달합니다.",

LLM>

"9.86억 vs 3.41억, 9.86억이 3.41억보다 6.45억 더 많습니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다.

9.86억과 3.41억의 차이는 6.45억입니다

Q357,D,하,"{"issuer": "을지대학교"}",**을지대학교 비교과시스템 개발 지시서에서, 마일리지 성적이 우수한 상위 동아리 학생 대표 5명에게 지급해야 하는 해외 유럽 배낭여행 연수 경비 바우처 금액은 1인당 몇 유로(Euro)로 잡혀 있습니까?**,

gt> "공고된 학사 비교과시스템 데이터 전산 구축망에는 학생 데이터 연계 API와 시스템 마일리지 연산 구조만 제안되었을 뿐, 실질적인 유럽 배낭여행 연수 현물 바우처 지급이나 유로화(Euro) 환율 단위의 예산 책정 등은 과업 대상과 무관하여 전혀 언급되지

않은 내역입니다.

LLM> ",1인당 500유로(Euro)로 잡혀 있습니다.

Q069,B,하,"{"issuer": {"\$in": ["국립중앙의료원",
"한국원자력연구원"]}},국립중앙의료원의 차세대 응급의료 상황관리시스템
예산(14억)과 한국원자력연구원의 선량평가시스템 고도화 예산 사이에 발생하는 차액은
얼마입니까?,

gt>

"국립중앙의료원 예산(1,400,000,000원)과 원자력연구원 고도화 예산(46,600,000원)
사이에는 총 1,353,400,000원의 차액이 발생합니다.",

LLM>

"국립중앙의료원의 차세대 응급의료 상황관리시스템 예산은 14억원이며,
한국원자력연구원의 선량평가시스템 고도화 예산은 46,600 천원입니다. 따라서 차액은
14,000,000,000 - 46,600 = 13,999,999,954,400입니다.",

- RAGAS 지표

RAGAS는 평가지표로 gpt4.1mini가 사용되었다. 이 모델에서 데이터를 로딩하는데,
기본적으로 실험했던, docs문서 수(10개)와 chunk per doc가 많았기에, 이를 RAGAS 지표로
그대로 찍어보기에 시간이 오래걸렸고, 진행 중 지속적인 에러로 인하여, faithfulness=0.35,
answer_relevancy=0.46 으로 마무리 지어야했다. 대신, 비록, 평가모델과 같긴하지만, llm
을 openAPI (gpt 4.1mini)로 사용하고 docs,와 chunks수(max_docs=5, chunks_per_doc=2,
max_total_chunks=8)를 대폭 줄임으로써, 결과를 보았을 때 아래의 표와 같은 결과를 확인
할 수 있었다.

	mean_score
faithfulness	0.7495
answer_relevancy	0.2207
context_precision	0.4444
context_recall	0.6056
answer_correctness	0.4139

[표8] RAGAS 평가지표

2. 신데이터 (125)

1) embedding model 및 retrieval전략_langchain

embedding model은 앞서 사용된 kurev1로 진행되었다. 이 모델을 가지고, 각 langchain전략을 구성해본 결과, hybrid rrf방식이 가장 좋은 결과로 이어졌다.

	strategy	strategy_name	questions	hit_rate	mrr	ndcg	recall
0	hybrid	hybrid_rrf_equal	30	1.000000	1.000000	0.919882	0.894444
1	hybrid_d20_s80	hybrid_20_dense_80_sparse	30	1.000000	1.000000	0.919882	0.894444
2	hybrid_d30_s70	hybrid_30_dense_70_sparse	30	1.000000	1.000000	0.919882	0.894444
3	hybrid_d50_s50	hybrid_50_dense_50_sparse	30	1.000000	1.000000	0.919882	0.894444
4	hybrid_d70_s30	hybrid_70_dense_30_sparse	30	1.000000	1.000000	0.919882	0.894444
5	hybrid_d80_s20	hybrid_80_dense_20_sparse	30	1.000000	1.000000	0.919882	0.894444
6	rerank	rerank_hybrid_cross_encoder	30	1.000000	1.000000	0.919882	0.894444
7	dense	basic_dense_kure	30	1.000000	1.000000	0.906987	0.877778
8	sparse	sparse_bm25	30	0.266667	0.244444	0.211315	0.216667

[표9] retrieval 성능비교

그러나 앞선 결과에서 볼 수 있었듯이, 예산문제에서 크고 작은 오류들이 발견되었기에, 이를 정교화시키는 과정으로 새 데이터가 구성되었고 이를 기반으로 retrieval방식을 구현하였다.

구체적으로, 예산문제에 대한 부분은 `UNIT_MULTIPLIER = { '원': 1, '만원': 10_000, '천원': 1_000, '백만원': 1_000_000, '억원': 100_000_000, 'None': 1, ':': 1,}`으로 정규화를 시켜주었다. 이는 retrieval이후 나온 결과가, 이 요소를 참조하여 변환할 수 있도록 구성하였다. 또한, 더 풍부해진 metdata항목을 적극 활용하여, type을 구성하였다. 예를 들어, budget의 type인 경우 아래와 같은 요소들이 들어갈 수 있도록 하였다.그 외에, 'budget': submission_documents:'eligibility': deadline':duration':purpose':comparison"general"으로 type을 나누었으며, general부분은 모든 질문영역에 다 포함될 수 있도록 구성하였다.

```

QUESTION_FACT_TYPES = {
    'budget': {'project_budget', 'budget', 'total_allocation', 'document_summary', 'estimated_price',
               'base_amount',
               'threshold_budget',
               'payment_terms',
               'reference_amount'},
}

if question_type == 'budget':
    if fact_type == 'project_budget':
        score += 60
    if to_bool(meta.get('budget_answer_enabled')):
        score += 50
    if answer_policy == 'allow_as_project_budget':
        score += 40
    if fact_type in {'threshold_budget', 'reference_amount', 'estimated_price', 'base_amount'}:
        score -= 35
    if answer_policy in {'route_only_not_final_answer', 'missing_project_budget'}:
        score -= 60

```

뿐만 아니라, 다양해진 metadata만큼, 기본 설정은 hybrid 50:50 이지만, 그다음 찾지 못하는 항목에 대해 rerank(rank-bm25) +ngram으로 후보군들안에서 찾을 수 있도록 설정하였고, 그 결과 아래와 같은 결과를 얻을 수 있었다.

questions	hit_rate	mrr	ndcg	recall
30	0.9	0.883333	0.846615	0.85

[표10] 결과

2) embedding model 및 retrieval전략_langGraph

전략은 위와 같고, LangGraph의 node와 edge 구조를 활용하여 검색 흐름을 제어하였다. 구체적으로, 각 처리 단계를 node로 정의하고, 조건에 따라 분기되는 edge를 통해 retrieval → 컨텍스트 구성 → 답변 생성의 파이프라인을 구성하였다. 이를 통해 단순한 순차 처리 방식인 LangChain과 달리, 검색 결과의 품질에 따라 rerank 또는 재검색을 수행하는 조건부 분기가 가능해졌다. 또한, 나라장터 API 호출 node를 별도로 구성하여, 공고번호 기반 조회 결과를 답변 생성 단계에 통합할 수 있도록 하였다.

그리고 나라장터 API를 가져와서 공고번호를 통해 결과를 불러올 수 있도록 진행하였다.

그결과, ndcg, recall부분에서 조금 향상된 수치를 확인할 수 있었다.

API 목록

GET	/getBidPblanListInfoCnstwk	입찰공고목록 정보에 대한 공사조회
GET	/getBidPblanListInfoServc	입찰공고목록 정보에 대한 용역조회
GET	/getBidPblanListInfoFrgcpt	입찰공고목록 정보에 대한 외자조회
GET	/getBidPblanListInfoThng	입찰공고목록 정보에 대한 물품조회
GET	/getBidPblanListInfoThngBsisAmount	입찰공고목록 정보에 대한 물품기초금액조회
GET	/getBidPblanListInfoEtcPPSSrch	나라장터검색조건에 의한 입찰공고 기타조회
GET	/getBidPblanListPPIFnRfpIssAtchFileInfo	입찰공고목록 정보에 대한 혁신장터 최종제안요청서 교부 첨부파일정보조회
GET	/getBidPblanListBidPrceCalcIAInfo	입찰공고목록 정보에 대한 입찰가격산식A정보조회
GET	/getBidPblanListEvaluationIndstryMfrcInfo	입찰공고목록 정보에 대한 평가대상 주력분야 조회
GET	/getBidPblanListInfoEtc	입찰공고목록 정보에 대한 기타공고조회
GET	/getBidPblanListInfoEorderAtchFileInfo	입찰공고목록 정보에 대한 e발주 첨부파일정보조회
GET	/getBidPblanListInfoFrgcptPurchsObjPrdct	입찰공고목록 정보에 대한 외자 구매대상물품조회

questions	hit_rate	mrr	ndcg	recall
30	0.9	0.883333	0.854436	0.861111

[표 11] 결과

3) LLM 과 RAGAS 성능지표비교(정성 및 정량평가)

- LLM

llm 자체 성능을 repetition을 변화를 주고 보았을 때,

do_sample=False, repetition_penalty=1.15, 일 때 결과가 가장 만족스러웠기에, 이 parameter로 고정하여 평가를 진행했다.

또한, prompt를 아래와 같이 진행하였다.

```

system_prompt = """
당신은 RFP 문서 검색 QA 어시스턴트입니다.
제공된 근거(context)에 있는 정보만 사용하세요.
내부 필드명, 정책명, fact_type, budget_answer_enabled, answer_policy, G2B manual lookup 같은 시스템 용어를 답변에 절대 노출하지 마세요.
context에 없는 URL, 기관명, 공고번호, 금액을 만들지 마세요.

사업 예산 금액은 근거에 명시된 경우에만 답하세요.
기초금액, 추정가격, 참가자격 기준금액, 입찰마감일, 사업기간은 사업 예산으로 말하지 마세요.

예산 금액이 없고 context에 나라장터 공고번호가 있으면:
- 예산 금액은 현재 근거에서 확인되지 않는다고 말하세요.
- 확인된 공고번호를 그대로 제시하세요.
- 나라장터 웹사이트에서 해당 공고번호로 확인하라고 안내하세요.
- 단, context에 없는 URL은 만들지 말고 https://www.g2b.go.kr/index.jsp 만 제시하세요.

예산 금액도 없고 공고번호도 없으면:
"문서 근거가 부족합니다."라고 간단히 답하세요.

답변은 3문장 이내로 작성하세요.
마지막 줄에 "출처: ..." 형식으로 context의 문서명 또는 확인 경로만 표시하세요.
""".strip()

user_prompt = f"""
[질문]
{question}

[근거]
{context}

[답변]
""".strip()

```

그결과, 아래 결과내용처럼, 일반 질문에 대해서 내용은 잘 뽑아내나, 특수기호포함이나
말로 풀어 설명하는 부분이 약함을 볼 수 있었다.뿐만 아니라 두번째 답변처럼, 모델이 그
내용을 찾을 수 없는 경우, 나라장터로 안내될 수 있도록 그 내용을 포함시켰다.

```

'mrrn': 1.0, 'ndcg': 1.0, 'recall': 1.0}],A,중,{ 'issuer': '한국가스공사'},[],[]
2005,그랜드코리아레저(주)의 그룹웨어 구축 사업에서 목표로 하는 시스템 개선의 대상 범위를 모두 열거해 주십시오.,“그랜드코리아레저(주)의 그룹웨어 구축 사업에서 목표로 하는 시스템 개선의 대상 범위는 다음과 같습니다:

```

1. 관리·사내 SNS(별별애기)·업무용 메신저 시스템의 관리 효율성 향상
2. 모바일 기능 구현으로 임직원의 사내 소통 강화 및 업무 처리 프로세스 재정립을 통한 사용자 편의 증대
3. 정보화 현황 가. 정보시스템 현황 □ 정보시스템 구성도 (필요시 보안서약서 작성 후 열람) □ 정보시스템 SW 현황(상세 버전정보 필요시 보안서약서 작성 후 열람) □ 정보시스템 인프라 현황 나. 정보시스템 기능 상세 □ 업무시스템 1. 추진 목표 □ 정부 표준 적용, 업무 프로세스 최적화 등 그룹웨어·기록물관리 시스템 구축을 통한 사용자 업무 효율성 증대
4. 업무용 메신저 시스템 재구축을 통한 안정적인 서비스 제공
5. 기존 생산된 전자 결재 문서를 포함한 대상 문서의 이관 및 데이터 마이그레이션
5. 기존·신규 시스템 연계 및 기관 환경 최적화를 위한 커스터마이징
7. 통합 검색 솔루션, 전자 결재·기록물관리 시스템 간 연계 등
3. 차세대 전자문서 유통시스템 기관 연계
3. 전자문서 유통시스템을 최신 기술로 문서 유통 체계 전환 연계 등

```

id,user_input,response,retrieved_contexts,reference,latency_sec,pipeline_latency_sec,ground_truth_docs,raw_retrieved_docs,raw_retr:
ma_where,g2b_contexts,g2b_calls
Q001,한국가스공사의 '차세대 통합정보시스템(ERP) 구축' 사업 예산 규모는 얼마입니까?,
"현재 근거에서 확인되지 않습니다. 확인된 공고번호는 2024080808001이며, 나라장터 웹사이트에서 해당 번호로 확인하시기 바랍니다. |

```

	mean_score		metric	mean_score
faithfulness	0.6885	0	faithfulness	0.672016
answer_relevancy	0.3099	1	answer_relevancy	0.286377
context_precision	0.5111	2	context_precision	0.488095
context_recall	0.5056	3	context_recall	0.488095
		4	answer_correctness	0.327970

[표 12] langchain과 langgraph 성능결과비교

- RAGAS 성능지표 및 추가적인 모델 평가 지표(phase3,4,) 활용 결과: langchain 와 langGraph 결과 비교

langGraph에서 체감상 retrieval이 잘 되었다는 만족과는 다르게, RAGAS 평가지표는 많이 달랐다. 그 이유를 살펴보면,

faithfulness zero_count: 1
 answer_relevancy zero_count: 9
 context_precision zero_count: 12
 context_recall zero_count: 13

와 같이 각 지표의 0값이 평균을 낮추고 있다고 볼 수 있다. 예를 들면, “예산 얼마인가?”가라는 질문에 대하여 “확인되지 않습니다. 공고번호로 확인하세요”라고 우회해도 relevancy 수치는 여전히 변동이 없기 때문이다.

뿐만 아니라, phase3,4,성능평가 모델을 이용하였을 때, 다음과 같이 볼 수 있듯이, 그 결과 또한 앞선 방식의 결과와 크게 다르지 않았다.

langchain	langGraph
원점수(1~5): 3.490 - 100점 환산: 69.8점 - 전체 판정: 제한적 참고 가능 - 가장 강한 항목: 위험 통제 (3.769) - 가장 약한 항목: 완전성 (3.051)	- 원점수(1~5): 3.435 - 100점 환산: 68.7점 - 전체 판정: 제한적 참고 가능 - 가장 강한 항목: 구조 명확성 (3.769) - 가장 약한 항목: 완전성 (3.103)

- risk_level 분포: {'low': 21, 'medium': 16, 'high': 2} - hallucination_risk 분포: {'low': 24, 'medium': 12, 'high': 3} - 사람 검토 필요 수: 18 - score cap 적용 수: 12 - LLM 총평 점수와 계산 점수 불일치 경고 수: 0	- risk_level 분포: {'low': 19, 'medium': 19, 'high': 1} - hallucination_risk 분포: {'low': 22, 'medium': 15, 'high': 2} - 사람 검토 필요 수: 20 - score cap 적용 수: 16 - LLM 총평 점수와 계산 점수 불일치 경고 수: 1
평균 답변 생성 시간 입력안됨.	- 평균 답변 생성 시간: 16.894초 - 중앙값 답변 생성 시간: 12.204초 - 최대 답변 생성 시간: 42.158초
이번 실험의 Phase 4 종합 점수는 69.8점으로, '제한적 참고 가능' 수준입니다. 위험 통제는 상대적으로 양호하지만 완전성이 가장 약하게 나타났습니다. 실무 사용 전에는 질문 요구사항 누락, 위험도 또는 핵심 항목 저점으로 인한 score cap, 사람 검토 필요 문항을 우선 확인하는 것이 좋습니다.	이번 실험의 Phase 4 종합 점수는 68.7점으로, '제한적 참고 가능' 수준입니다. 구조 명확성은 상대적으로 양호하지만 완전성이 가장 약하게 나타났습니다. 실무 사용 전에는 질문 요구사항 누락, 위험도 또는 핵심 항목 저점으로 인한 score cap, 사람 검토 필요 문항을 우선 확인하는 것이 좋습니다.

평가 항목	내부 컬럼	평균 점수(1~5)	100점 환산	해석
실무 유용성	business_usefulness_score	3.538	70.8	RFP 실무자가 답변을 실제 업무에 참고할 수 있는 정도
완전성	completeness_score	3.051	61.0	질문과 근거 요약 기준으로 필요한 요소를 충분히 다뤘는지
근거성	groundedness_score	3.513	70.3	답변이 검색 근거와 source_docs에 기반했는지
숫자/사실 정확성	numeric_factuality_score	3.744	74.9	금액, 날짜, 기간, 자격, 제출서류 등 사실 정보가 위험하게 틀리지 않았는지
구조 명확성	structure_clarity_score	3.564	71.3	문서별 요약, 비교축, 항목 구분 등 답변 구조가 읽기 쉬운지
위험 통제	risk_control_score	3.769	75.4	문서에 없는 단정, 과장, 환각 위험을 억제했는지
종합 점수	calculated_overall_score	3.490	69.8	세부 점수 가중합과 cap rule을 반영한 공식 Phase 4 종합 점수

[표 13] langchain 세부평가결과

평가 항목	내부 컬럼	평균 점수(1~5)	100점 환산	해석
실무 유용성	business_usefulness_score	3.462	69.2	RFP 실무자가 답변을 실제 업무에 참고할 수 있는 정도
완전성	completeness_score	3.103	62.1	질문과 근거 요약 기준으로 필요한 요소를 충분히 다뤘는지
근거성	groundedness_score	3.462	69.2	답변이 검색 근거와 source_docs에 기반했는지
숫자/사실 정확성	numeric_factuality_score	3.538	70.8	금액, 날짜, 기간, 자격, 제출서류 등 사실 정보가 위험하게 틀리지 않았는지
구조 명확성	structure_clarity_score	3.769	75.4	문서별 요약, 비교축, 항목 구분 등 답변 구조가 읽기 쉬운지
위험 통제	risk_control_score	3.692	73.8	문서에 없는 단정, 과장, 환각 위험을 억제했는지
종합 점수	calculated_overall_score	3.435	68.7	세부 점수 가중합과 cap rule을 반영한 공식 Phase 4 종합 점수

[표 14] langchain 세부평가결과

3. 결론

본 실험은 크게 구데이터(125개), 신데이터(125개)를 중심으로 진행되었다. Embedding & Retrieval에서는 KURE_v1이 다른 모델보다 전반적으로 우수함을 보였다. 그러나, B타입(다중 문서 비교)에 취약한 점을 보완하고자, metadata의 agency 항목을 issuer와 일치시키는 조건을 전제로 retrieval을 수행하였다. 한국어 문서 특화모델이라는 점에서, LLM을 한국어기반 모델로 찾고자 하였으며, multilingual 모델보다, sh2orc/Llama-3.1-Korean-8B-Instruct가 답변 품질이 나왔기에, 이를 선택하여 진행했다. 이 과정에서, 주요 문제 3가지가 발견되었는데, 그것은 답변의 반복 생성과 환각, 예산부분에서의 오류였다. 이 문제는 repetition_penalty와 수정보완된 데이터 내의 구조를 활용한 context와의 연결성, 정규화 등으로 해결하고자 했다.

뿐만 아니라, LangChain 방식과 LangGraph 방식을 이용하여, 비교실험을 해본 결과, langchain방식은 hit_rate: 0.9, mrr: 0.883, ndcg: 0.846, recall: 0.85로, LangGraph방식은 hit_rate : 0.9, mrr: 0.883, ndcg:0.854, recall: 0.8611 로, ndcg와 recall에서 소폭 향상되어, 조건부 분기 구조가 retrieval 정밀도 개선에 일부 기여함을 확인하였다.

체감 retrieval 품질은 LangGraph가 더 나왔으나, 자체 개발한 Phase 4 종합 평가지표를 참고하였을 때, 각 모델의 성능평가도는 69.8점, 68.7점으로, 둘 다 "제한적 참고 가능" 수준에 머물렀다. LangGraph에서 나라장터의 API를 활용해 문서가 없는 답변에 한에, 공고번호로 결과를 도출하는 방법이 실질적 relevancy 점수에 큰 도움이 되지 못한 것으로 분석된다.